

O corpus do projeto: a Baixada Santista nos verbetes da Wikipédia

Equipe FFV | 7 de outubro de 2026

Fatec Baixada Santista, Rubens Lara | Tecnologia em Ciência de Dados
Projeto Integrador III: Motor de Busca | Prof. Dr. João Paulo Ferreira de Mello

Felipe Steinfeld, RA 0051352511017

Flávia Alessandra da Silva Barbosa, RA 0051352511018

Victor Gabriel Leme da Silva, RA 0051352421012

Repositório: <<https://github.com/vicleme/PI3-FFV>>

1 Introdução

Este projeto constrói, em R e sem bibliotecas de busca, um motor de busca sobre a Baixada Santista (SP), região da Fatec que abriga o maior porto da América Latina e um grande polo industrial. Quem o usaria é, por exemplo, um estudante, um morador ou um visitante que precisa de um fato pontual (um ano, um número, um nome) e não quer ler três verbetes inteiros para achá-lo. Em recuperação de informação (RI), atende-se a *necessidade de informação* de alguém, não a consulta literal (MANNING; RAGHAVAN; SCHÜTZE, 2008, cap. 1); por isso as perguntas vêm antes do corpus. Três delas guiam este texto: qual cidade abriga o maior porto da América Latina, em que ano Cubatão se tornou município e como funciona a travessia de balsa entre Santos e Guarujá (são dez no total). Este texto apresenta a fonte, descreve como o corpus foi montado e mostra que ele serve.

2 A fonte e o documento

O texto vem da Wikipédia em português, sob a licença Creative Commons Atribuição-CompartilhaIgual (CC BY-SA), que permite guardá-lo e redistribuí-lo no repositório com atribuição. As páginas são os verbetes *Santos* (SANTOS, 2026), *Cubatão* (CUBATÃO, 2026) e *Guarujá* (GUARUJÁ, 2026), acessados em ago. de 2026. São cidades vizinhas, ligadas pelo porto e pela travessia, e os verbetes se cruzam: o de Guarujá cita Cubatão como distrito industrial, e a resposta pode estar na página vizinha.

Um documento é um parágrafo do verbete, isto é, um bloco separado por linha em branco, identificado como `Santos_p1`, `Santos_p2` e assim por diante. É a menor unidade que responde sozinha a uma pergunta: o verbete inteiro faria a busca dizer “está em Santos” sem dizer onde, e uma frase isolada perderia o contexto (MANNING; RAGHAVAN; SCHÜTZE, 2008, seq. 2.1.2). O corpus tem $N = 63$ documentos de 3 páginas.

Escolhemos o tema por proximidade (a região é a da faculdade), por disponibilidade (texto aberto, em português, obtido por API, sem raspagem) e porque os verbetes se sobrepõem, o que dá ao motor algo a distinguir. Descartamos notícias de jornais regionais, que têm direitos reservados e exigiriam raspagem, o que impediria redistribuir o corpus.

3 Como o corpus foi obtido

O script `00-preparar-corpus.R` consulta a API da Wikipédia (extratos em texto puro, com redirecionamentos) para os três títulos e grava cada resposta em UTF-8 em `estrutura/corpus/`. Depois, `utils-corpus.R` quebra cada texto em parágrafos nas linhas em branco, apara espaços e descarta blocos vazios, e o resultado é exportado para `paragrafos.csv`. Não usamos limiar de tamanho: o menor parágrafo tem 221 caracteres, então um corte em 200, como o do modelo, não removeria nenhum.

Três coisas deram errado. O corpus nasceu com um documento por cidade, apenas três, escala muito maior que a das frases curtas de exemplo; o professor apontou o descompasso e passamos aos parágrafos. Os verbetes eram baixados da API a cada execução, deixando os resultados à mercê da rede e de edições na Wikipédia; passamos a gravar os `.txt` e lê-los do disco, o que fixa uma versão. Por fim, no primeiro TF-IDF, os termos de maior peso de Cubatão incluíram nomes próprios citados de passagem (como “passarelli” e “marcia”), raros mas sem relação com a cidade; é um limite do modelo, e não da coleta, e fica registrado.

4 Defesa do corpus

As Tabelas 1 e 2 reúnem o diagnóstico do corpus e a origem dos documentos.

Tabela 1 – Diagnóstico do corpus

Verificação	Resultado
Tamanho	63 documentos de 3 páginas
Tokens por documento	33 a 124 (média 73,3)
Vocabulário bruto	1.791 termos distintos em 4.617 tokens
Página que domina	Santos: 23 de 63 (37%)
Documentos suspeitos	0 com menos de 20 tokens; 0 com mais de 300
Sujeira	63 com acento, 63 com pontuação, 56 com dígitos (de 63)

Fonte: Elaborada pelos autores a partir de `paragrafos.csv`.

Tamanho e domínio. São 63 documentos, três acima do teto de 60 da entrega, por dividir em parágrafos; mantivemos todos. Nenhuma página domina: Santos tem 37% dos documentos, contra 20 de cada uma das outras, por ter o verbete mais longo.

Tabela 2 – Documentos por página de origem


Página	Documentos	Tokens (média)
Santos	23	76,4
Cubatão	20	69,7
Guarujá	20	73,3

Fonte: Elaborada pelos autores.

Documentos que não são prosa. Nenhum documento é curto ou longo demais (de 33 a 124 tokens), mas, ao conferir os últimos parágrafos de cada verbete, vimos que `Cubatao_p20` e `Guaruja_p20` são listas de indicadores do Censo de 2010 em frases curtas. Mantivemos os dois: o de Cubatão responde à pergunta sobre a população da cidade pelo Censo.

Sujeira. Acentos, pontuação e dígitos aparecem como esperado em texto bruto; a normalização fica para o pré-processamento. A Figura 1 mostra que metade dos documentos tem entre 58 e 88 tokens, sem cauda longa.

Figura 1 – Tokens por documento



Fonte: Elaborada pelos autores.

Os termos mais frequentes são `de`, `a`, `o`, `e`, `do`, `da`, `em`, `com`, `é`, `que`: todas palavras funcionais, nenhum diz algo sobre o tema. Isso motiva o pré-processamento e o peso IDF.

Veredito. As dez necessidades têm ao menos um parágrafo de grau 2 (que responde) no gabarito, 14 ao todo, julgados pelos três integrantes sobre 630 pares de consulta e documento: três para o porto (`Santos_p1`, `p18` e `p19`), dois para a emancipação de Cubatão (`Cubatao_p8` e `p9`) e um para a balsa (`Guaruja_p19`). O corpus contém, portanto, as respostas; o que falta é ranqueá-las, e a pergunta sobre o polo industrial, que o verbete chama de “parque industrial”, já mostra essa dificuldade. A concordância entre os juízes, medida pelo κ de Cohen (1960), foi moderada a boa (0,50 a 0,62), limitada por não termos combinado critérios antes de julgar. Nenhum descarte removeu documentos e, como o gabarito foi julgado sobre estes 63, mudar o corpus obrigaria a rejulgar tudo; as próximas etapas devem mexer nos modelos, não nos documentos.

Referências

- COHEN, J. A coefficient of agreement for nominal scales. *Educ. Psychol. Meas.*, v. 20, n. 1, p. 37–46, 1960.
- CUBATÃO. In: WIKIPÉDIA: a enciclopédia livre. [S. l.]: Wikimedia Foundation, 2026. Disponível em: <<https://pt.wikipedia.org/wiki/Cubat%C3%A3o>>. Acesso em: ago. 2026.
- GUARUJÁ. In: WIKIPÉDIA: a enciclopédia livre. [S. l.]: Wikimedia Foundation, 2026. Disponível em: <<https://pt.wikipedia.org/wiki/Guaruj%C3%A1>>. Acesso em: ago. 2026.
- MANNING, C. D.; RAGHAVAN, P.; SCHÜTZE, H. *Introduction to information retrieval*. Cambridge: Cambridge University Press, 2008.
- SANTOS. In: WIKIPÉDIA: a enciclopédia livre. [S. l.]: Wikimedia Foundation, 2026. Disponível em: <<https://pt.wikipedia.org/wiki/Santos>>. Acesso em: ago. 2026.