

O corpus do projeto: *escreva aqui o tema, em uma linha*

Nome do Grupo

25 de setembro de 2026

Fatec Baixada Santista – Rubens Lara

Tecnologia em Ciência de Dados | Projeto Integrador III — Motor de Busca | Prof. Dr.
João Paulo Ferreira de Mello

Nome Completo do Integrante 1 – RA 00000000000000

Nome Completo do Integrante 2 – RA 00000000000000

Nome Completo do Integrante 3 – RA 00000000000000

Repositório: projeto-nome-do-grupo

ATENÇÃO: compilado com o corpus de teste da aula, não com o do grupo.

1 Introdução

Apresente o tema e diga por que ele interessa, e a quem. Em recuperação de informação, o que se atende é a *necessidade de informação* de alguém, não a consulta literal (MANNING; RAGHAVAN; SCHÜTZE, 2008, cap. 1); por isso as perguntas vêm antes do corpus. Feche o primeiro parágrafo dizendo, em uma frase, o que este texto faz: apresenta a fonte escolhida, descreve como o corpus foi montado e mostra que ele tem condição de responder às perguntas.

2 A fonte e o documento

Descreva a origem, com a referência (Wikimedia Foundation, 2026), a licença e a data de acesso. Liste as páginas. O corpus tem $N = 8$ documentos vindos de 2 páginas.

Diga o que é um documento e justifique. Um artigo inteiro como documento faz a busca devolver “a resposta está no artigo de X” sem dizer onde; o parágrafo é o padrão do curso, mas o grupo pode ter decidido outra coisa — e então explica.

Explique a escolha do tema e da fonte, e a alternativa descartada.

3 Como o corpus foi obtido

Descreva os passos. O critério de documento foi “parágrafo com mais de 200 caracteres”; diga como esse número foi escolhido.

Conte o que deu errado e o que mudou por causa disso.

4 Defesa do corpus

A Tabela 1 reúne as verificações feitas sobre o corpus, e a Tabela 2 mostra de onde veio cada documento.

Tabela 1 – Diagnóstico do corpus

Verificação	Resultado
Tamanho (N documentos, páginas)	8 documentos de 2 páginas
Tokens por documento	6 a 9 (média 8)
Vocabulário bruto	45 termos distintos em 64 tokens
Página que domina	Corpus da aula (A) : 4 de 8 (50%)
Documentos suspeitos	8 com menos de 20 tokens; 0 com mais de 300
Sujeira	0 com acento, 0 com pontuação, 1 com dígitos (de 8)

Fonte: Elaborada pelos autores a partir de `docs.rds` e `origem.rds`.

Tabela 2 – Documentos por página de origem

Página	Documentos	Tokens (média)
Corpus da aula (A)	4	7,8
Corpus da aula (B)	4	8,2

Fonte: Elaborada pelos autores.

Tamanho. São 8 documentos; a meta desta entrega é 20 a 60. Comente se o corpus está na faixa e, se não, o que o grupo pretende fazer.


Domínio de uma página. A Tabela 2 diz se uma página responde por quase tudo. Diga se isso é a cara do tema ou um desequilíbrio a corrigir — acrescentando páginas, não cortando.

Documentos que não são prosa. Os extremos da Tabela 1 (muito curtos, muito longos) costumam ser listas, tabelas ou seções de referências. Diga se o grupo olhou esses documentos e o que fez.

Sujeira. Acentos, pontuação grudada e dígitos são esperados nesta altura — a limpeza é a Aula 03. Registre o que foi visto, sem resolver.

A Figura 1 mostra a distribuição dos tamanhos.

Figura 1 – Tokens por documento



Fonte: Elaborada pelos autores.

Os termos mais frequentes são de, a, documentos, e, busca, modelo, o, recuperacao, relevancia, acelera. Diga quantos deles dizem algo sobre o tema — e o que isso sugere sobre as próximas aulas.

Veredito. Feche dizendo se o corpus responde às três perguntas da Introdução. Se um descarte pegou, diga o que mudou no corpus por causa dele — um corpus corrigido por evidência vale mais do que um corpus que nunca foi examinado.

O corpus é **provisório**: cresce na Aula 05, quando o grupo montar o gabarito, e depois congela. Registre em uma frase o que as próximas aulas podem mudar nele.

Referências

MANNING, C. D.; RAGHAVAN, P.; SCHÜTZE, H. *Introduction to Information Retrieval*. Cambridge: Cambridge University Press, 2008.

Wikimedia Foundation. *Wikipédia, a enciclopédia livre*. 2026. <<https://pt.wikipedia.org>>. Conteúdo sob licença CC BY-SA 4.0. Acesso em: <dia mês ano>.